

IA, SHS et épidémiologie : une recherche expérimentale sur des matrices de contact synthétiques françaises et des agents comportementaux

Martin Collins

15 avril 2026

Résumé

Les matrices de contact par âge sont devenues un ingrédient standard de la modélisation épidémiologique, mais leur construction reste délicate lorsque l'on cherche à concilier ancrage empirique, transparence des hypothèses et reproductibilité. Pour la France, l'enquête COMES-F constitue une référence précieuse, sans pour autant fournir à elle seule une solution générale dès que l'on souhaite tester des variantes méthodologiques, préparer des déclinaisons territoriales ou documenter des hypothèses simplifiées. Nous partons ici d'une question volontairement modeste : jusqu'où peut-on aller avec des modèles de référence frugaux, explicites et faciles à reproduire, puis avec une couche d'agents LLM pensée comme recherche expérimentale au croisement de l'IA, des SHS et de l'épidémiologie ?

Le manuscrit présente un cadre expérimental incrémental. La première étape compare une repondération démographique minimale à un modèle de référence structuré par contextes de contact. La seconde optimise directement ce modèle de référence sur COMES-F. La troisième ajoute une couche comportementale temporelle calibrée sur des séries françaises. La quatrième mobilise 22 profils socio-démographiques et des appels réels à Claude Sonnet 4.6 via OmniMart sur six régimes sanitaires. Les résultats montrent qu'un modèle de référence contextuel simple surpasse nettement la repondération démographique et que son optimisation sur COMES-F améliore encore la MAE de 23,8%. La calibration temporelle améliore l'ajustement en apprentissage mais reste fragile hors échantillon, surtout pour SocialCov. Enfin, les agents LLM restituent correctement la hiérarchie des régimes sanitaires, avec une réduction moyenne de mobilité passant de 0,04 en pré-pandémie à 0,68 lors du premier confinement, et font apparaître une forte hétérogénéité sociale de réactivité, favorable aux profils cadres et défavorable aux profils agricoles. L'apport principal est donc moins une promesse de substitution aux données qu'un protocole transparent permettant d'identifier ce que chaque couche du modèle capte réellement, ce qu'elle

échoue encore à capter, et comment l’IA peut servir de dispositif expérimental transversal entre domaines plutôt que de solution magique.

Mots-clés. matrices de contact, intelligence artificielle, SHS, modélisation épidémiologique, France, recherche expérimentale

1 Introduction

Les matrices de contact par âge occupent une place décisive dans les modèles de transmission, parce qu’elles traduisent en structure quantitative la manière dont les générations se rencontrent dans la vie ordinaire. Elles interviennent aussi bien dans l’estimation du nombre de reproduction que dans l’évaluation d’interventions ciblées, la comparaison de scénarios vaccinaux ou l’interprétation d’hétérogénéités d’incidence entre groupes d’âge. Pourtant, entre l’existence d’enquêtes empiriques de grande qualité et les besoins concrets des modélisateurs, un espace méthodologique reste souvent mal couvert. On dispose soit de matrices observées, précieuses mais limitées à un certain contexte de collecte, soit de projections synthétiques à large couverture, utiles mais parfois difficiles à discuter finement lorsqu’une question nationale précise est posée.

Le cas français illustre bien cette tension. COMES-F fournit un repère empirique particulièrement solide pour la France (Béraud et al., 2015), et les travaux internationaux de projection ont considérablement élargi la disponibilité des matrices de contact (Prem et al., 2017, 2021). Néanmoins, lorsqu’il s’agit d’élaborer un pipeline français reproductible, facile à auditer et suffisamment souple pour accueillir des extensions futures, il manque encore un niveau intermédiaire. Ce niveau n’est ni une simple réutilisation d’une matrice publiée, ni un générateur socio-démographique complet. Il s’agit plutôt d’un cadre de modèles de référence clairement formulés, assez frugaux pour rester lisibles, mais assez structurés pour rendre visibles les gains apportés par chaque hypothèse supplémentaire.

C’est dans cette perspective que s’inscrit ce travail. Nous comparons un modèle de repondération démographique à un modèle plus structuré, organisé par contextes de contact et inspiré d’hypothèses simples sur les ménages, la scolarisation, l’activité professionnelle et les interactions communautaires. L’ambition reste volontairement limitée : établir un socle expérimental propre, traçable et extensible, puis mesurer ce que l’on gagne réellement lorsque l’on passe d’heuristiques fixes à des paramètres appris sur données françaises. Le cadre est explicitement celui d’une recherche expérimentale mêlant intelligence artificielle, SHS et épidémiologie : les agents LLM ne servent pas ici à remplacer les données, mais à tester des hypothèses comportementales transversales entre domaines. Plus précisément, l’article poursuit cinq objectifs :

- proposer un cadre de comparaison reproductible pour des matrices de contact synthétiques françaises simples ;
- évaluer ce qu’une structuration explicite par contextes apporte, en pratique, par rapport à une adaptation démographique minimale ;
- estimer directement sur COMES-F les poids des composantes domicile-école-travail-autres afin de tester si la version heuristique peut être améliorée sans perdre en interprétabilité ;
- examiner, sur séries temporelles françaises, jusqu’où une calibration comportementale légère améliore réellement la généralisation hors échantillon ;
- tester si une couche agentique fondée sur 22 profils socio-démographiques et des générations LLM réelles restitue des contrastes temporels et sociaux défendables dans le cas français.

Notre contribution est donc triple. Premièrement, nous montrons qu’une modèle de référence contextuel très simple peut encore être resserrée par optimisation directe sur COMES-F. Deuxièmement, nous testons honnêtement une calibration comportementale avec séparation apprentissage/validation, ce qui permet de distinguer les gains reproductibles des améliorations purement in-sample. Troisièmement, nous documentons ce que des agents LLM captent effectivement lorsqu’on les ancre dans des profils sociaux explicites : la hiérarchie des régimes sanitaires et une partie des écarts de capacité d’ajustement, mais pas encore l’ensemble de la dynamique observée.

2 Travaux connexes

Les enquêtes de contacts restent le point de départ le plus convaincant pour décrire les mélanges intergénérationnels pertinents en santé publique. POLYMOD a joué, à cet égard, un rôle fondateur en montrant la robustesse de certains motifs de contact, notamment l’assortativité par âge et l’importance des contextes quotidiens (Mossong et al., 2008). Pour la France, COMES-F a apporté un ancrage empirique décisif en documentant les contacts déclarés, leurs variations selon le calendrier et la nécessité de corriger certains biais de réciprocité (Béraud et al., 2015). Ces travaux constituent davantage qu’une source de comparaison : ils fixent aussi les propriétés minimales qu’une matrice synthétique crédible devrait retrouver, au moins grossièrement.

Une seconde famille de travaux vise moins à mesurer directement les contacts qu’à les projeter dans des pays ou des régions dépourvus d’enquêtes dédiées. Les matrices de Prem et collègues ont ici fait référence, en combinant enquêtes existantes, structures démographiques, organisation scolaire et participation au travail pour produire des matrices synthétiques à large couverture géographique (Prem et al., 2017, 2021). Cette approche est extrêmement utile, et nous en retenons l’idée centrale selon laquelle une décom-

position par contextes facilite la transférabilité. En revanche, notre objectif est plus restreint. Il ne s’agit pas de reconstruire un modèle hiérarchique international, mais d’examiner ce que l’on peut obtenir dans un cadre français plus léger, où les hypothèses restent immédiatement inspectables.

Une troisième ligne de recherche pousse la synthèse beaucoup plus loin en construisant des populations artificielles riches, à partir de microdonnées socio-démographiques et de mécanismes explicites d’affectation aux ménages, aux écoles ou aux lieux de travail (Mistry et al., 2021). Ces pipelines offrent un réalisme structurel nettement supérieur et ouvrent la voie à des analyses fines, notamment à l’échelle infranationale. Ils exigent toutefois davantage de données, davantage de choix de modélisation et, souvent, une chaîne de validation plus lourde. Notre travail se situe en amont de cette ambition. Il réemploie l’intuition des composantes domicile-école-travail-autres, simplifie fortement la représentation des structures sociales et laisse hors champ, à ce stade, la synthèse complète de populations, la dynamique temporelle détaillée et la modélisation régionale.

Enfin, les travaux récents sur la France ont rappelé qu’une matrice de contact n’est pas un objet figé. Les enquêtes répétées et les jeux de données ouverts sur les comportements barrières montrent combien les profils de contact et de prévention se transforment selon les périodes et les contraintes sanitaires (Soussand et al., 2025; Bosetti and Opatowski, 2024; Santé publique France, 2021). Cette littérature est essentielle pour penser des matrices effectives dépendantes du temps. Elle ne remplace toutefois pas une base statique bien identifiée. Il semble donc utile de disposer d’abord d’un socle français simple, reproductible et correctement évalué, avant de lui adjoindre des mécanismes de variation temporelle plus ambitieux.

3 Méthodologie

Le protocole repose sur une discrétisation commune en $K = 17$ classes d’âge couvrant l’intervalle $[0, 85]$ ans selon une grille régulière. Une matrice de contact est notée $M \in \mathbb{R}_+^{K \times K}$, où l’entrée M_{ij} représente l’intensité moyenne de contact d’un individu du groupe i avec le groupe j . Dans cette première étape, l’objet d’intérêt n’est pas la reconstitution exhaustive d’un système social français, mais l’évaluation de ce que des hypothèses minimales permettent déjà de reproduire. Cette restriction de périmètre est importante : elle rend les choix de modélisation inspectables et limite le risque d’attribuer à des mécanismes complexes un gain qui viendrait en réalité d’un simple effet de structure.

Les entrées du pipeline sont volontairement peu nombreuses. On utilise un vecteur de population par âge $\mathbf{p} = (p_1, \dots, p_K)$, strictement positif, ainsi que quatre composantes de contact initiales correspondant au domicile, à l’école, au travail et aux autres interactions communautaires. Dans l’expé-

rience initiale, ces composantes ont d’abord été produites par un générateur synthétique déterministe avant d’être confrontées ensuite à COMES-F réel pour la validation structurelle et l’optimisation contextuelle. Elles sont symétrisées avant usage, de sorte que la matrice de référence R vérifie une contrainte minimale de réciprocité agrégée. Ce choix peut sembler conservateur, mais il évite d’introduire trop tôt des artefacts d’orientation qui brouilleraient l’interprétation des modèles de référence.

Le premier modèle de référence, dit *demographic scaling*, part d’une matrice gabarit agrégée

$$T = H + S + W + O,$$

où H , S , W et O désignent respectivement les composantes *home*, *school*, *work* et *other*. Chaque ligne de T est d’abord normalisée, puis repondérée par la masse démographique du groupe émetteur :

$$\widehat{M}_{ij}^{\text{demo}} = \frac{T_{ij}}{\sum_{\ell=1}^K T_{i\ell}} p_i.$$

La formule est volontairement sobre. Elle capte l’effet mécanique d’une structure d’âge cible, sans chercher à modifier la topologie de la matrice gabarit. Autrement dit, ce modèle répond à la question suivante : que gagne-t-on si l’on adapte uniquement l’exposition démographique, en laissant inchangée l’architecture des contacts sous-jacente ?

Le second modèle de référence introduit une structure plus interprétable. On construit séparément quatre composantes, puis on les additionne. La composante domicile combine une diagonale de cohabitation, des bandes parent-enfant, un terme de proximité conjugale et une interaction grand-parent/enfant de plus faible intensité. La composante scolaire est concentrée autour des âges de scolarisation, avec une forte composante quasi diagonale et un couplage plus diffus vers les adultes. La composante professionnelle est plus large en âge, afin de refléter une activité de travail étalée sur plusieurs décennies. Enfin, une composante communautaire de faible amplitude ajoute un fond de mélange non spécifique. Formellement, on peut écrire

$$\widehat{M}^{\text{hh}} = M^{\text{home}} + M^{\text{school}} + M^{\text{work}} + M^{\text{other}}.$$

Chaque terme est ensuite pondéré par une exposition démographique de type $\sqrt{p_i p_j}$, ce qui évite qu’un groupe peu nombreux reçoive un poids excessif tout en conservant une lecture simple de la contribution des tailles de groupes.

Les profils d’âge utilisés dans ce modèle sont définis par fenêtres lissées. On distingue notamment les enfants, les âges scolaires, les jeunes adultes, les âges d’activité et les seniors. Les matrices de bande sont générées à partir d’une décroissance gaussienne selon la distance entre indices d’âge, ce qui permet d’induire naturellement une assortativité locale sans régler une multitude de paramètres. Les intensités numériques retenues n’ont pas vocation

à être lues comme des paramètres estimés ; elles servent surtout à fixer un régime de comparaison cohérent entre composantes. En ce sens, le modèle est plus proche d’une référence mécaniste transparente que d’un estimateur statistique.

La question de la réciprocité mérite d’être explicitée. Dans une matrice de contacts agrégée, on attend souvent que les déséquilibres entre M_{ij} et M_{ji} restent limités après correction démographique. La baseline structurée est construite de manière essentiellement symétrique, si bien que son écart de réciprocité devrait rester faible, voire nul dans cette implémentation. À l’inverse, le modèle de repondération démographique peut introduire une asymétrie moyenne dès lors que le redressement agit uniquement sur la dimension émettrice. Ce contraste est méthodologiquement utile : il permet de mesurer si un faible coût de modélisation suffit déjà à restaurer une propriété structurelle souvent jugée souhaitable.

Enfin, l’ensemble du protocole a été conçu pour être extensible. Une première extension consiste à optimiser les poids des composantes du modèle structuré directement sur COMES-F. Une seconde consiste à ajouter une couche comportementale calibrable sans remettre en cause la décomposition précédente. Le point central, à ce stade, est moins l’ambition descriptive que la lisibilité de la chaîne de production et la possibilité de quantifier honnêtement ce que chaque couche supplémentaire apporte, ou n’apporte pas.

Une extension supplémentaire, plus explicitement SHS, introduit non pas une population synthétique complète, mais 22 profils-situations couvrant dix grandes positions socio-démographiques françaises : ouvriers, employés, cadres, professions intermédiaires, retraités, étudiants, personnes inactives, artisans ou commerçants, agriculteurs et chômeurs. Chaque profil combine un âge dominant, une configuration résidentielle, un degré de contrainte de mobilité, un niveau de flexibilité numérique et un proxy prudent de confiance institutionnelle. L’objectif n’est pas de faire comme si ces profils représentaient des individus observés. Il est de créer un niveau intermédiaire, lisible et discutable, entre des séries nationales agrégées et une modélisation agentique plus lourde. Leur définition combine trois familles de sources : la nomenclature française des positions sociales et des catégories socio-professionnelles (INSEE, 2016), les structures de ménages plausibles (INSEE, 2021), et la différenciation des possibilités de télétravail (DARES, 2024). Les gradients de prévention visibles dans CoviPrev servent ensuite d’ancrage qualitatif pour éviter des profils arbitraires (Santé publique France, 2021).

Le générateur comportemental associé est implémenté comme un module d’appel à un grand modèle de langage, avec consignes courtes, sortie JSON contrainte, cache local systématique et limitation simple de débit. Dans le run final analysé ici, les générations sont produites par Claude Sonnet 4.6 routé via OmniMart. Pour chaque couple profil-période, le modèle renvoie cinq scores bornés entre 0 et 1 : réduction de mobilité, distanciation sociale,

adhésion au masque, perception du risque, confiance dans les mesures. Les six périodes retenues sont la situation pré-pandémique de référence, le premier confinement, le déconfinement de l’été 2020, les restrictions de seconde vague, le couvre-feu hivernal 2020-2021 et la phase du passe sanitaire. La réduction de mobilité simulée est comparée à un indice agrégé construit à partir des rapports officiels Google Community Mobility Reports pour la France (Google, 2022). Les niveaux de prévention ne sont pas interprétés comme des mesures individuelles exactes, mais comme un test de cohérence descriptive avec CoviPrev. Enfin, pour comparer les profils entre eux, nous définissons une réactivité moyenne comme la différence entre la pré-pandémie et le premier confinement, moyennée sur les cinq dimensions comportementales. Cette métrique simple permet de lire les hiérarchies sociales produites par le modèle sans prétendre les essentialiser.

4 Expériences

L’évaluation principale s’appuie désormais sur une double logique. Une première expérience interne, enregistrée sous l’identifiant `exp001_baseline_comparison`, a servi à valider la cohérence du pipeline sur données synthétiques contrôlées. La validation structurelle réellement mobilisée dans l’article repose cependant sur COMES-F réel, via `exp001_real` puis `exp004`. Cette organisation conserve un intérêt pratique évident : elle fige les chemins d’artefacts, explicite la politique de graine aléatoire et permet de rejouer les expériences sans dépendance implicite à un environnement externe.

La politique de reproductibilité est volontairement stricte. Une graine unique, fixée à 2026 dans la configuration actuelle, alimente les phases synthétiques du pipeline, tandis que les phases de validation structurelle et temporelle reposent sur des jeux réels distincts : COMES-F, CoviPrev, SocialCov et Google Mobility. Les artefacts intermédiaires sont conservés afin de distinguer clairement ce qui relève du banc d’essai interne et ce qui relève d’une validation empirique.

Quatre familles d’indicateurs sont calculées. L’erreur absolue moyenne (MAE) renseigne sur l’écart cellule à cellule moyen entre matrice prédite et référence. La distance de Frobenius mesure un désajustement global plus sensible aux erreurs de grande amplitude. L’assortativité par âge est résumée par deux parts : la masse diagonale stricte, puis la masse concentrée sur la diagonale et ses voisines immédiates. Enfin, l’écart de réciprocité est défini comme la moyenne des asymétries absolues entre cellules symétriques. Ensemble, ces indicateurs ne couvrent pas toute la validité d’une matrice de contact, mais ils offrent déjà une lecture différenciée de l’erreur, de la structure d’âge et de la cohérence interne.

La procédure d’évaluation suit toujours le même ordre. On prépare d’abord les données d’entrée, on calcule ensuite les modèles de référence

structuraux, puis les couches temporelles et agentiques. Les métriques sont dérivées automatiquement et résumées dans des rapports JSON et des figures de synthèse. Les chemins de sortie ont été fixés dès les premières expérimentations, ce qui a permis de substituer les jeux réels aux jeux placeholder sans casser la structure générale du protocole.

Une seconde étape, `exp003_time_series_behavioral`, évalue explicitement cette couche sur des données temporelles françaises. Les comportements observés proviennent des vagues nationales 17 à 28 de CoviPrev (Santé publique France, 2021). Les changements de contacts proviennent des six matrices ordonnées du dépôt SocialCov (Bosetti and Opatowski, 2024). Les régimes de politique publique sont alignés sur une chronologie institutionnelle française (Vie publique, 2024). L’expérience reste prudente : elle ne prétend pas reconstruire un comportement latent individuel, mais tester si une couche bornée et pilotée par les politiques publiques capture mieux qu’une référence statique les variations observées au cours de la pandémie.

5 Résultats

Les deux modèles de référence produisent des profils très contrastés. La repondération démographique conserve la forme globale de la matrice gabarit, mais elle s’écarte fortement de la référence dès que l’on considère les amplitudes absolues. À l’inverse, le modèle structuré par contextes obtient un niveau d’erreur très faible sur l’ensemble des indicateurs retenus. Le résultat est suffisamment net pour que l’on puisse parler, dans ce cadre expérimental précis, d’un bénéfice substantiel lié à l’introduction d’une structure minimale par contextes.

TABLE 1 – Comparaison quantitative des modèles de référence statiques.

Modèle	MAE	Distance de Frobenius	Part diagonale	Écart de réciprocité
Repondération démographique	6,48	198,42	0,240	4,22
Heuristique ménage	0,35	8,82	0,139	0,00
Optimisation ménage	0,27	7,17	0,163	0,00

L’ampleur des écarts mérite d’être commentée. Une MAE de 6,48 et une distance de Frobenius de 198,42 indiquent que le modèle démographique reste loin de la référence, malgré une diagonale relativement marquée. Cette dernière propriété n’est pas anodine : elle suggère qu’une simple repondération par âge tend à préserver, voire à accentuer, une forme d’assortativité locale déjà présente dans le gabarit. Mais cette proximité apparente sur la diagonale ne suffit pas. Les intensités hors diagonale, ainsi que l’équilibre entre groupes d’âge, demeurent mal restitués. L’écart de réciprocité de 4,22 confirme d’ailleurs qu’un ajustement unilatéral par lignes peut dégrader une propriété structurelle pourtant souhaitable dans une matrice agrégée.

Le comportement du modèle structuré est d’une autre nature. Avec une MAE de 0,35, une distance de Frobenius de 8,82 et un écart de réciprocity nul, la version heuristique reproduit déjà beaucoup plus fidèlement la matrice de référence dans ce banc d’essai. L’optimisation directe des poids domicile-école-travail-autres sur COMES-F améliore encore ce résultat : la MAE descend à 0,27, soit un gain relatif d’environ 23,8%, et la distance de Frobenius passe à 7,17. Le fait que ce gain reste modéré, et non spectaculaire, est important. Il suggère que l’essentiel de la performance vient bien de la structure contextuelle elle-même, pas seulement d’un réglage opportuniste des coefficients.

Les figures 1 à 3 complètent cette lecture. Elles montrent d’une part la proximité visuelle entre la référence et la référence ménage, d’autre part le décalage beaucoup plus net de le modèle démographique sur les intensités et la symétrie. Le profil d’assortativité par âge est particulièrement instructif. Le modèle démographique concentre davantage de masse sur la diagonale stricte, alors que le modèle structuré diffuse plus naturellement les contacts vers les bandes voisines, ce qui est cohérent avec l’idée de contextes sociaux mixtes, notamment au domicile et au travail.




FIGURE 1 – Comparaison visuelle entre la référence, la repondération démographique et le modèle structuré par contextes.




FIGURE 2 – Comparaison des principales métriques d’erreur et de cohérence structurelle.




FIGURE 3 – Profil d’assortivité par âge pour les deux modèles de référence et la référence empirique.

Pour une lecture orientée santé publique, le signal principal est donc moins la valeur absolue d’une métrique isolée que la combinaison de trois propriétés : proximité globale à la référence, stabilité de la réciprocity et capacité à redistribuer les contacts au-delà de la diagonale stricte. Sous cet angle, le modèle structuré paraît constituer un socle nettement plus crédible pour des extensions ultérieures.

La validation temporelle nuance toutefois ce tableau. Une fois les fenêtres exactes de collecte SocialCov réalignées à partir de la figure de recrutement publiée, le signal reste contrasté. Sur CoviPrev, la couche comportementale non calibrée réduit toujours la MAE de l’indice de prévention de 0,124 à 0,054 par rapport à une référence statique, avec un accord directionnel de 0,73. Sur SocialCov, en revanche, ce même réalignement rend l’ajustement plus difficile : la MAE sur les changements de contacts relatifs monte à 0,265, contre 0,174 pour la référence statique, même si l’accord directionnel reste supérieur à zéro (0,40 contre 0,00). Autrement dit, l’apport dynamique dépend sensiblement de l’alignement temporel retenu, ce qui invite à la prudence.

Nous avons ensuite calibré la couche comportementale sur une partition chronologique. L’apprentissage utilise les vagues CoviPrev 17 à 23 et les quatre premières périodes SocialCov ; la validation porte sur les vagues CoviPrev 24 à 28 et sur les deux dernières périodes SocialCov. Le résultat est volontairement présenté tel quel. En apprentissage, la calibration réduit fortement la MAE de prévention (0,046 à 0,019) et améliore aussi la MAE de contacts (0,144 à 0,106). Hors échantillon, l’image est plus mitigée : pour la prévention, la MAE se dégrade légèrement par rapport à la couche non calibrée (0,063 contre 0,056), tout en restant bien meilleure qu’une référence statique (0,196). Pour les contacts SocialCov, la calibration améliore modes-

tement la MAE hors échantillon (0,305 à 0,274), mais elle reste nettement moins bonne que la référence statique (0,121). La contribution défendable n'est donc pas d'avoir obtenu une calibration robuste en tout point. Elle est d'avoir montré où la calibration aide, où elle surapprend, et pourquoi les conclusions temporelles restent fragiles avec si peu de périodes observées.

TABLE 2 – Synthèse des métriques temporelles après réaligement SocialCov et calibration.

Série et modèle	MAE	Accord directionnel	Précision du pic
Prévention, comportemental non calibré	0,054	0,73	0,50
Prévention, statique	0,124	0,00	0,50
Contacts, comportemental non calibré	0,265	0,40	1,00
Contacts, statique	0,174	0,00	0,20
Prévention test, calibré	0,063	0,50	0,20
Contacts test, calibré	0,274	1,00	1,00

Les figures correspondantes montrent bien cette dissymétrie. La série CoviPrev observée décroît globalement entre novembre 2020 et octobre 2021, avec un rebond au moment du troisième confinement. Le modèle reproduit cette pente générale et ce rebond, mais il surestime encore le niveau de prévention lors du retour du passe sanitaire. Côté contacts, le modèle suit correctement certaines inflexions de politique publique, mais il reste sensible au choix des fenêtres temporelles et sous-estime encore la reprise observée en fin de période.

Un second bloc de résultats porte sur les profils socio-démographiques et le générateur comportemental de type LLM. Contrairement aux versions intermédiaires du pipeline, l'exécution archivée ici repose bien sur des appels réels à Claude Sonnet 4.6 via OmniMart, avec 22 profils et six régimes de politique publique. Le premier résultat est un gradient temporel net et cohérent avec l'histoire sanitaire : la réduction moyenne de mobilité simulée passe de 0,04 en pré-pandémie à 0,68 lors du premier confinement, avant de redescendre à 0,26 au déconfinement puis de remonter à 0,45 pendant la seconde vague et à 0,55 sous couvre-feu. L'adhésion moyenne au masque suit elle aussi une trajectoire plausible, de 0,15 avant crise à 0,66 au premier confinement, puis 0,71 lors de la seconde vague et 0,76 pendant le couvre-feu. Le modèle capture donc bien le sens général du choc pandémique et des périodes restrictives.

L'ajustement agrégé à Google Mobility reste toutefois imparfait. Sur les six régimes, la corrélation entre réduction de mobilité simulée et réduction observée vaut 0,72, avec une MAE de 0,168. Le classement des périodes est donc correctement restitué dans son ensemble, mais les niveaux restent surestimés hors des moments de confinement strict. L'écart est particulièrement

TABLE 3 – Résumé des sorties LLM agrégées par régime sanitaire.

Régime	Mobilité LLM	Mobilité observée	Masque LLM
Pré-pandémie	0,04	0,05	0,15
Premier confinement	0,68	0,63	0,66
Déconfinement	0,26	0,18	0,57
Deuxième vague	0,45	0,29	0,71
Couvre-feu	0,55	0,27	0,76
Passe sanitaire	0,50	0,06	0,50

visible pour le couvre-feu et, surtout, pour la séquence du passe sanitaire, où les agents maintiennent un niveau de restriction comportementale bien supérieur à celui observé dans les données de mobilité. Cette erreur n’invalidé pas le module. Elle indique plus précisément ce qu’il capte bien, à savoir le sens des ruptures politiques, et ce qu’il capte mal, à savoir la normalisation progressive des pratiques en 2021.

Le résultat le plus intéressant pour les SHS concerne la hiérarchie de réactivité entre profils. La métrique de réactivité moyenne entre pré-pandémie et premier confinement place en tête le profil *cadre 35-49 en couple avec enfants* avec un delta de 0,65. À l’autre extrême, le profil *agriculteur 50-64 en couple* n’atteint que 0,26. L’écart est donc de 0,394 point entre le profil le plus réactif et le moins réactif. Cette hiérarchie n’est pas socialement neutre. Les profils cadres cumulent télétravail, flexibilité numérique et maintien d’une confiance relativement élevée dans les mesures. Les profils agricoles ou ouvriers restent davantage contraints par le présentiel, la continuité de l’activité et un moindre levier d’ajustement résidentiel ou professionnel.

La comparaison directe entre un profil cadre et un profil agricole rend ce contraste plus lisible encore. Sur les trois périodes les plus restrictives, le profil *cadre 35-49 en couple avec enfants* atteint en moyenne 0,82 de réduction de mobilité, 0,83 d’adhésion au masque et 0,69 de confiance dans les mesures. Le profil *agriculteur 50-64 en couple* reste nettement plus bas, avec respectivement 0,39, 0,47 et 0,48. Ce différentiel est sociologiquement plausible, car il renvoie à des inégalités concrètes de marge de manoeuvre face aux politiques publiques. Il doit toutefois être interprété comme une hypothèse produite par un simulateur, non comme une mesure directe des groupes sociaux français.

Ces résultats sont résumés dans les figures 6, 7 et 8. Elles montrent conjointement la bonne restitution du gradient de politique publique, la dispersion des réactivités entre profils et le contraste marqué entre un profil cadre et un profil agricole. L’intérêt du module n’est donc pas de fournir une vérité sociale clé en main. Il est de rendre explicites, auditables et discutables les hypothèses distributives qu’un modèle agentique injecte dans la dynamique comportementale.




FIGURE 4 – Indice de prévention observé dans CoviPrev et simulé par la couche comportementale.

6 Discussion

Le premier enseignement est assez clair. Dans ce cadre expérimental, une modèle de référence frugal mais structurée surpasse très largement une adaptation purement démographique. Ce constat rejoint, sous une forme volontairement simplifiée, l'intuition centrale des travaux de projection par contextes : la structure du mélange social ne peut guère être résumée par la seule démographie. Les composantes domicile, école, travail et communauté n'épuisent certes pas la variété des situations sociales, mais leur explicitation suffit déjà à réintroduire des motifs de contact essentiels, notamment la co-existence d'assortativité scolaire et de ponts intergénérationnels au sein des ménages.

Le résultat n'invalide pas pour autant l'intérêt des approches très sobres. Le modèle démographique remplit une fonction utile, précisément parce qu'elle constitue un contrepoint lisible. Elle montre ce qu'une simple correction de masse démographique peut préserver, et ce qu'elle ne parvient manifestement pas à reconstituer. Un tel modèle reste précieuse comme borne inférieure méthodologique, pour vérifier qu'un gain de performance n'est pas artificiellement attribué à une complexité superflue. À cet égard, l'expérience suggère qu'il existe bien un premier seuil de complexité justifié scientifiquement : la décomposition contextuelle minimale.

La place de ce travail dans la littérature doit donc être formulée avec prudence. Il ne s'agit ni d'une alternative complète aux enquêtes françaises comme COMES-F, ni d'un concurrent direct des grands pipelines internationaux ou des générateurs de populations synthétiques riches. En revanche, l'étude apporte un argument méthodologique utile : avant de mobiliser des architectures lourdes, il est possible, et sans doute souhaitable, de documenter ce qu'apporte chaque couche de structure avec un protocole léger




FIGURE 5 – Changements de contacts relatifs observés dans SocialCov et simulés par la couche comportementale.

mais traçable. Cette logique incrémentale paraît particulièrement adaptée aux projets nationaux où les données existent, mais doivent être progressivement harmonisées.

Le pas suivant, scientifiquement défendable, n’est probablement pas un raffinement arbitraire des heuristiques actuelles. Il semble plus pertinent d’ajouter une couche de variation dépendante des politiques publiques et des comportements, tout en conservant le socle contextuel comme référence statique. Les résultats montrent toutefois que cette intuition ne se traduit pas uniformément en gain hors échantillon. Oui, l’optimisation de le modèle statique est utile : elle améliore nettement COMES-F sans dégrader l’interprétabilité. Oui aussi, une couche comportementale bornée aide à suivre la prévention observée. Mais non, la calibration actuelle ne transforme pas encore le modèle en bon prédicteur temporel des contacts SocialCov. Le tableau honnête est donc celui d’une progression asymétrique : la partie statique se renforce, tandis que la partie dynamique reste davantage démonstrative qu’aboutie.

L’expérience par profils ajoute un second enseignement, désormais mieux étayé puisqu’elle repose sur des générations LLM effectives et non sur une branche de secours heuristique. Les agents restituent bien la hiérarchie des régimes sanitaires et font émerger des écarts sociaux plausibles de capacité d’ajustement. Le contraste entre profils cadres et profils agricoles n’est pas un détail anecdotique : il signale que le modèle intègre, puis redistribue, des ressources inégalement disponibles face aux politiques publiques. C’est précisément ce qui rend l’objet intéressant pour les SHS. Mais c’est aussi ce qui impose de le traiter comme un dispositif réflexif. Le simulateur ne découvre pas des essences sociales. Il réarticule des hypothèses de classe, de




FIGURE 6 – Réduction de mobilité agrégée des agents LLM, comparée à l’indice observé de Google Mobility, avec rappel de l’adhésion moyenne au masque.

travail, de logement et de confiance institutionnelle que nous avons nous-mêmes encodées, puis que le modèle de langage amplifie ou réordonne.

Il faut enfin rappeler que la portée externe des conclusions reste limitée. Une bonne performance sur une matrice nationale agrégée, et plus encore sur un nombre réduit de régimes sanitaires, ne garantit ni une validité régionale, ni une robustesse temporelle, ni une pertinence immédiate dans des contextes postérieurs aux grands chocs sanitaires récents. La valeur du présent travail tient donc surtout à sa fonction de socle expérimental auditable. C’est un résultat modeste, mais utile : il clarifie ce qu’une chaîne frugale, calibrée puis augmentée par agents LLM, peut soutenir comme interprétation, et ce qu’elle ne doit pas encore prétendre expliquer.

7 Limites

La première limite est la plus évidente : une première phase du protocole a bien utilisé une matrice de substitution interne. Elle ne doit pas être confondue avec la validation empirique ultérieure sur COMES-F réel, désormais intégrée au papier. Les bonnes performances du modèle structuré sur le banc d’essai interne restent donc secondaires par rapport au résultat principal, à savoir l’amélioration observée sur COMES-F réel après optimisation contextuelle. Une conclusion encore plus robuste exigerait cependant une harmonisation plus complète des pondérations d’enquête et des contacts professionnels additionnels.

Une deuxième limite tient au caractère heuristique des paramètres. Les profils de participation scolaire, professionnelle ou domestique, de même que les intensités relatives des composantes, ne sont pas ici estimés à partir de microdonnées françaises. Ils sont choisis pour produire un modèle plausible,




FIGURE 7 – Classement des 22 profils selon leur réactivité moyenne entre la pré-pandémie et le premier confinement.

lisible et stable numériquement. Cette orientation est assumée, mais elle restreint la portée descriptive du modèle. Si l'on souhaitait avancer une interprétation substantielle des coefficients, il faudrait alors introduire un travail de calibration bien plus rigoureux, probablement appuyé sur des sources INSEE, des enquêtes emploi du temps ou des données complémentaires de mobilité.

Une troisième limite concerne le niveau d'agrégation. Réduire la population à 17 groupes d'âge sur une seule matrice nationale efface des hétérogénéités importantes : différences territoriales, contrastes socio-professionnels, hétérogénéité intra-ménage, spécificités calendaires et effets de contexte institutionnel. Une telle agrégation est défendable pour un premier modèle de référence, mais elle devient insuffisante dès que l'on cherche à raisonner sur des politiques localisées ou sur des calendriers fins. De la même manière, la couche comportementale ajoutée dans `exp003` ne produit qu'une dynamique agrégée guidée par les régimes de politique publique, et non des estimations observées des comportements collectifs individuels.

Une quatrième limite est spécifique aux données temporelles mobilisées ici. Le classeur CoviPrev téléchargé publiquement renseigne bien plusieurs indicateurs de prévention, mais pas directement la perception du risque, qui reste donc traitée comme une variable latente guidée par les politiques publiques et l'usure comportementale. Les fenêtres SocialCov ont pu être ré-




FIGURE 8 – Contraste de comportement entre un profil cadre et un profil agricole sur les périodes les plus restrictives.

alignées plus précisément grâce à la figure de recrutement de l'article publié, mais cette amélioration ne supprime pas le problème principal : six périodes seulement sont observées, dont deux dans l'échantillon de validation chronologique. Une calibration qui semble convaincante en apprentissage peut donc surapprendre très vite, comme le suggèrent nos résultats hors échantillon et certaines ablations favorables à des modèles simplifiés.

Une cinquième limite concerne directement le module LLM par profils. Les appels utilisés ici sont réels, mais cela ne règle pas la question de la validation. D'abord, les cibles comportementales restent indirectes, car l'extrait public CoviPrev exploité ici est national et non entièrement stratifié par PCS. Ensuite, les 22 profils-situations sont des objets analytiques construits à partir de marges publiques et de proxys raisonnés, pas des observations individuelles. Enfin, même avec des générations LLM effectives, un tel dispositif reste exposé à un double risque : aplatir les écarts sociaux en produisant des profils trop moyens, ou au contraire figer des stéréotypes en reconduisant trop directement les descripteurs de classe, d'âge ou de genre codés dans les prompts. Le fait que le modèle accentue fortement le différentiel cadres-agriculteurs rend ce point méthodologiquement central plutôt qu'accessoire.

Enfin, l'évaluation mobilise un nombre réduit de métriques. MAE, distance de Frobenius, assortativité locale et réciprocité offrent une lecture utile, mais partielle. Nous avons ajouté une première couche de robustesse, avec analyse de sensibilité, ablations et intervalles bootstrap. Ces vérifications montrent que les conclusions dynamiques restent fragiles, en particulier du côté SocialCov, où retirer certaines composantes améliore parfois la MAE de test. D'autres critères seraient néanmoins nécessaires pour soutenir des

affirmations plus fortes : stabilité sous changement de binning, sensibilité aux perturbations de population, adéquation des composantes contextuelles, ou encore impact sur les sorties d'un modèle épidémique aval. Tant que ces vérifications n'ont pas été menées, il serait imprudent d'aller au-delà de conclusions méthodologiques circonscrites.

8 Conclusion

Cette étude montre qu'un cadre expérimental très simple peut déjà être informatif, à condition de rendre explicites les hypothèses qu'il mobilise. Dans le dépôt actuel, le modèle structuré par contextes reproduit nettement mieux la référence de travail que la seule repondération démographique, et son optimisation directe sur COMES-F améliore encore la MAE d'environ 23,8% par rapport à la version heuristique. Le point important n'est pas seulement la différence de performance. C'est aussi le fait qu'un gain substantiel soit obtenu avec une architecture encore lisible, facilement rejouable et suffisamment légère pour servir de base commune à des comparaisons futures. Pour un projet appliqué à la modélisation épidémiologique française, cette sobriété méthodologique a une valeur pratique réelle : elle facilite l'audit scientifique, la maintenance du code et la discussion des hypothèses avec des utilisateurs non spécialistes du pipeline.

L'étape suivante est désormais mieux délimitée. Il faudra, d'une part, conserver le socle statique optimisé comme point d'ancrage méthodologique. Il faudra, d'autre part, enrichir la dynamique temporelle avec des covariables réellement observées et davantage de points de calibration, car la calibration comportementale actuelle n'apporte qu'un gain partiel hors échantillon : utile sur la prévention, plus fragile sur les contacts, et globalement fragile selon les ablations. Dans son état actuel, la contribution défendable pour une thèse n'est donc pas une prétention à prédire fidèlement la dynamique française, mais un résultat plus utile scientifiquement : montrer comment passer d'un modèle statique transparent à une extension temporelle elle aussi transparente, puis mesurer honnêtement ce qu'elle gagne et ce qu'elle ne gagne pas.

Le module par profils ouvre une piste complémentaire désormais substantielle. Avec des appels réels à Claude Sonnet 4.6 via OmniMart, il restitue correctement l'ordre des régimes sanitaires et fait émerger une forte différenciation sociale de réactivité, au bénéfice des profils cadres et au détriment des profils agricoles. Ce résultat est assez net pour être sociologiquement intéressant, mais pas assez validé pour être naturalisé. Sa valeur est ailleurs : il montre comment relier des séries agrégées à des positions sociales nommées, expliciter les hypothèses distributives du simulateur et rendre auditables les biais qu'il transporte. Si cette logique incrémentale est maintenue, le projet devrait pouvoir évoluer vers des matrices plus crédibles sans perdre la qualité la plus utile à ce stade : la transparence.

Références

- Guillaume Béraud, Sophie Kazmerczak, Philippe Beutels, Daniel Levy-Bruhl, Xavier Lenne, Nathalie Mielcarek, Yazdan Yazdanpanah, Pierre-Yves Bo"elle, Niel Hens, and Benoit Dervaux. The french connection : The first large population-based contact survey in france relevant for the spread of infectious diseases. *PLoS ONE*, 10(7) :e0133203, 2015. doi : 10.1371/journal.pone.0133203.
- Paolo Bosetti and Lulla Opatowski. Data repository for "evolution of social contacts patterns in france over the sars-cov-2 pandemic : results from the socialcov survey", 2024. URL <https://zenodo.org/records/13834596>. Zenodo dataset, accessed for ordered period-specific French contact matrices.
- DARES. Le télétravail en 2024, 2024. URL <https://dares.travail-emploi.gouv.fr/publication/le-teletravail-en-2024>. Mobilisé pour coder la flexibilité différentielle des catégories d'emploi face aux restrictions.
- Google. Covid-19 community mobility reports, 2022. URL <https://www.google.com/covid19/mobility/>. Archive publique des rapports de mobilité, arrêtée au 15 octobre 2022.
- INSEE. Professions et catégories socioprofessionnelles (PCS), 2016. URL <https://www.insee.fr/fr/statistiques/1288152>. Référence mobilisée pour ancrer les profils socio-professionnels français utilisés dans l'expérience LLM.
- INSEE. Ménages, familles et situations résidentielles en france, 2021. URL <https://www.insee.fr/fr/statistiques/2381486>. Repères utilisés pour documenter les structures de ménages plausibles des profils synthétiques.
- Dhruvil Mistry, Maria Litvinova, Ana Pastore y Piontti, Matteo Chinazzi, Laura Fumanelli, Marcelo F. C. Gomes, M. Elizabeth Halloran, Ira M. Longini, Stefano Merler, and Alessandro Vespignani. Inferring high-resolution human mixing patterns for disease modeling. *Nature Communications*, 12(1) :323, 2021. doi : 10.1038/s41467-020-20544-y.
- Jo"el Mossong, Niel Hens, Mark Jit, Philippe Beutels, Kari Auranen, Rafael Mikolajczyk, Marco Massari, Stefania Salmaso, Gianpaolo Scalia Tomba, Jacco Wallinga, Janneke Heijne, Malgorzata Sadkowska-Todys, Magdalena Rosinska, and W. John Edmunds. Social contacts and mixing patterns relevant to the spread of infectious diseases. *PLoS Medicine*, 5(3) :e74, 2008. doi : 10.1371/journal.pmed.0050074.
- Kiesha Prem, Alex R. Cook, and Mark Jit. Projecting social contact matrices in 152 countries using contact surveys and demographic data. *PLoS*

Computational Biology, 13(9) :e1005697, 2017. doi : 10.1371/journal.pcbi.1005697.

Kiesha Prem, Kevin van Zandvoort, Petra Klepac, Rosalind M. Eggo, Nicholas G. Davies, Alex R. Cook, and Mark Jit. Projecting contact matrices in 177 geographical regions : An update and comparison with empirical data for the covid-19 era. *PLoS Computational Biology*, 17(7) :e1009098, 2021. doi : 10.1371/journal.pcbi.1009098.

Santé publique France. Données d'enquête relatives à l'évolution des comportements et de la santé mentale pendant l'épidémie de covid-19 (CoviPrev), 2021. URL <https://www.data.gouv.fr/fr/datasets/donnees-denquete-relatives-a-levolution-des-comportements-et-de-la-sante-mentale-pendant-lepidemie-de-covid-19-coviprev/>. Jeu de données ouvert sur data.gouv.fr, consulté pour les vagues nationales 17 à 28.

Flora Soussand, Armiya Youssouf Abdou, et al. Evolution of social contacts patterns in france over the sars-cov-2 pandemic : Results from the socialcov survey. *BMC Infectious Diseases*, 25 :224, 2025. doi : 10.1186/s12879-025-10611-4.

Vie publique. Chronologie des mesures sanitaires liées à la covid-19, 2024. URL <https://www.vie-publique.fr/en-bref/273947-covid-19-chronologie-des-mesures-sanitaires>. Chronologie institutionnelle des principales mesures nationales en France.

[title=Références]